

週次MTGレポート — 2026-08-20

背景・目標

前回（8/6）のFBで「タイトル予測より既存ベンチマークを上げる方がイメージに合う」「Geminiなど最近のAIと比較したい」という方向性を確認した。今週はこれを受けて、意匠特許の図面画像から「見た目が紛らわしい製品同士を正しく見分けられるか」を測る多肢選択ベンチマークを新規に構築し、ファインチューニングなしの汎用マルチモーダルAIでの最初の評価結果を得た。

1. 今週の結果

1-1. 形状類似製品を見分ける4択ベンチマークの構築


意匠図面1枚を見せて、正しい製品名1つと、見た目が紛らわしい誤答3つの計4択から選ばせる形式のベンチマークを構築した。誤答は、テキストを一切使わず画像同士の見た目の近さだけで選定しており、「実際には別カテゴリの製品だが、外形が似ているために紛らわしい」誤答を意図的に混ぜる設計にしている。

構築の過程で、誤答の中に正解の単なる言い換え・表記ゆれ（例：同じ製品を指す "Suitcase" と "Luggage" のような組み合わせ）が紛れ込んでしまうケースが一定数見つかったため、意味的な近さを別途チェックして除外する仕組みを追加した。最終的に2022年データ全件（31,470件）に対して4択問題セットを完成させている。

1-2. サンプル20件の目視確認


ベンチマークがちゃんと機能しているか（画像と設問がずれていないか、誤答が見た目の紛らわしさとして妥当か）を確認するため、先頭20件を画像付きで目視確認した。

設問1



- A. Battery pack
- B. Water heater
- C. Data output interface
- D. **Data reader (正解)**

設問2



- A. Panel tread for a paving system
- B. Organizer system and components of the organizer system
- C. **Panel light (正解)**
- D. Medication case

設問3




FIG. 1




FIG. 2

- A. Flip mount
- B. Optical end effector
- C. Night vision goggle
- D. **Massager** (正解)

設問4





FIG. 1


- A. Small trolley case
- B. Storage cabinet handle
- C. **Luggage** (正解)
- D. Travel kit

設問5



- A. Electronic non-contact infrared thermometer X5
- B. Motor vehicle body, toy replica and/or other replica
- C. Articulating blade assembly for hair removal device
- D. **Wall-mounted safe (正解)**


設問6



- A. Dial


- B. Decorative element for jewellery
- C. Watch case
- D. **Pair of earrings** (正解)

設問7



- A. Trash can
- B. Air purifier
- C. **Container** (正解)
- D. Vacuum bottle

設問8



- A. Dispenser
- B. Ultrasonic imaging diagnostic device
- C. **Razor hanger** (正解)
- D. Hat hook for wall mount

設問9



- A. Toy (正解)
- B. Buckle dinosaur pillow
- C. Unicorn shaped game board
- D. Inflatable toy

設問10




Fig. 1

- A. Firearm suppressor
- B. Flashlight with an electronic insect repellent
- C. **Single shot protection device (正解)**
- D. Flashlight

設問11





FIG. 1


- A. In vitro diagnostic device (IVD)
- B. Cat feeder
- C. Charging plug
- D. **Pet feeding station** (正解)

設問12




- A. Folding table
- B. Display sign
- C. Adjustable free standing sneeze guard
- D. **Plant grow light** (正解)

設問13



- A. Power grinder
- B. Disc cutter
- C. **Portable electric circular saw** (正解)
- D. Holster

設問14



- A. Cable management device
- B. Exercise weight device

- C. Tire for automobile
- D. **Tire for motorcycle** (正解)


設問15

1



- A. **Toilet paper holder** (正解)
- B. Angled hinge hanger with elongated vertical tube
- C. Door handle
- D. Faucet

設問16



- A. Men's recovery garment
- B. **Underwear with folded diagonal fly (正解)**
- C. Underwear
- D. Underwear with pouch with curved double darts

設問17

Fig.1





Fig.2



- A. Vacuum insulated bowl
- B. Flask
- C. Ultrasonic transducer for a fish finder
- D. **Powder compact** (正解)

設問18




FIG. 1

- A. Head light
- B. Vehicle taillamp
- C. **Vehicle front headlamp daytime running lights (正解)**
- D. Taillight for a vehicle

設問19




FIG. 1

- A. Cut stone for jewelry
- B. Animal habitat
- C. Scope warmer apparatus
- D. **Sanitizable device case** (正解)

設問20




FIG. 1

- A. **Stepper**（正解）
- B. Footwear midsole and outsole
- C. Shoe
- D. Shoe sole tread

分かったこと

- 1. **画像と設問のズレは見つからなかった。** 20件全て、表示されている図面と正解タイトルが正しく対応している。
- 2. **誤答は「意味的に近い」だけでなく「見た目としても紛らわしい」ものが選ばれている。** 例えば設問20は正解が「Stepper」（足踏み運動器具）だが、誤答には靴底・靴のパーツ関連が3つ並んでおり、実際の画像も足裏の形をした凹凸のある面という、靴のインソール・アウトソールと見分けが難しい形状になっている。誤答が単なる同義語の言い換えではなく、本当に形状ベースで紛らわしい候補になっていることが確認できた。
- 3. **同一カテゴリ内の細かい違いを問う設問もある。** 設問16は正解・誤答ともに「下着」の一種で、股上の縫製の違いという細部でしか区別できない設問になっている。これは以前対応した「単なる同義語・表記ゆれの混入」とは異なり、正当に難しい（=見分けるべき）設問だと判断している。

1-3. zero-shotベースラインの評価結果

完成した4択セット全件に対し、ファインチューニングなしの汎用マルチモーダルAI（Qwen3-VL-4B）で回答させた。

精度結果（n=31,470）

指標	値
正答率	54.84%
ランダム推測	25.00%

正答率が低かったロカルノ分類（下位5件）：

分類	内容	正答率	件数
食料品	お菓子・パン等の加工食品	37.2%	121
時計・計測機器	時計，各種計測機器	46.1%	989
医療・実験用器具	医療用及び実験用の機器	46.7%	1,874
照明用機器	各種照明器具	48.6%	1,525
電気機器	発電・変電・配電機器	49.8%	1,612

分かったこと

1. **正答率はランダム推測の2倍以上あり、ゼロショットでも形状の手がかりをある程度使えていることが分かる。** 一方で100%には遠く、「見た目が紛らわしい誤答」を混ぜるという設計が狙い通りに機能し、易しすぎず難しすぎない適度な難易度のベンチマークになっている。
2. **正答率が低い分野には共通する傾向がある。** 食料品、時計・計測機器、照明器具、医療・実験用器具はいずれも、丸型・直方体・塊状といった汎用的な外形が、互いに無関係な製品同士で繰り返し現れやすい分野である。逆に言えば、画像の見た目の近さだけで誤答を選ぶという今回のマイニング方法が、「本質的に形状だけでは区別しにくい」紛らわしさを的確に捉えられていることの裏付けにもなっている。

1-4. ファインチューニング後モデルでの評価結果

zero-shotと全く同じテストセット・同じ聞き方で、意匠タイトルの自由記述予測用に別途LoRAファインチューニング済みのモデル（2021年データで学習）にも解かせた。このモデルは4択の見分け方自体を学習したことは一度もなく、「タイトルを言い当てる」学習で得た知識がこの4択タスクにどこまで転移するかを見る位置づけ。

精度結果（n=31,470、zero-shotと同一テストセット）

指標	zero-shot	タイトル特化ファインチューニング後
正答率	54.84%	56.36%
ランダム推測	25.00%	25.00%

分かったこと

1. **ファインチューニング後は正答率が+1.51pt向上した（54.84%→56.36%）。** 4択の解き方自体は一度も学習していないモデルでも、タイトルを言い当てる学習で得た製品知識がこの見分けタスクに一定転移することが分かった。
2. **正答率が低い分野の顔ぶれが入れ替わった。** zero-shotで特に苦手だった食料品・医療実験用器具は、ファインチューニング後は下位グループから外れるほど改善した一方、輸送機器・家庭用品・調理用機械などが新たに正答率下位に入ってきた。タイトル予測の学習データに多く含まれていた分野の知識は転移しやすく、そうでない分野は相対的に取り残されている可能性がある。

2. 今後やること

- ファインチューニング前後で正答率が低い分野の顔ぶれが入れ替わった理由を、学習データに含まれる分野の分布と突き合わせて確認する

- 正答率が低かった分野について誤答の具体例を確認し、モデルがどのような形状の特徴を見誤っているのか定性的に分析する

3. FB

作成: 2026-08-20